双 H100 十六天 FastConformer ASR 从零训练计划

状态：执行方案，尚未执行。日期：2026-10-27。 PDF 阅读版 · 简短 TTS 备选 · 方案索引。推荐用两张 H100 做一条 约 115M-class、英文、离线 FastConformer-CTC，在 LibriSpeech 三个训练划分上从随机权重开始。默认主训练最多 50 次自然数据暴露，Day 3 – 14 训练，Day 15 – 16 完整评测与交付；模型质量由结果判定，十六天不是准确率承诺。总时钟从未来获准执行的 T0 起连续计算 384 小时，包含下载、工程、等待、失败与恢复，不因故障重置。本轮只交付方案，没有连接 GPU、下载数据、安装环境或启动训练，也没有新的吞吐、参数量或 WER 实测。本文配置是待合并的差异片段，涉及的预算/恢复包装器尚未实现。

决策项	本轮固定范围	执行时仍须验证
模型	17 层、宽度 512、8 heads、CTC；所有参数随机初始化	精确参数量、固定版兼容性、CTC 数值与显存
数据	LibriSpeech train-clean-100/360、train-other-500；train-only BPE256	校验、解码、20 秒训练过滤后的真实小时与条数
资源	最多 2×H100；保守按每卡 80GB，不预设 NVLink	实际显存、驱动、互联、独占、磁盘与 I/O
主训练	默认 50 次暴露；global batch 128；一个种子	Day 2 实测能否在剩余窗口完成；否则预先缩量
截止	Day 14 末停止训练，Day 16 末交付；不自动延长	统一时钟、可恢复保存和两卡一致停止适配
评价	完整双 dev 选模；完整双 test，greedy，无外部 LM	全部句子、分子分母、长句与失败记录完整

1. 固定十七层模型，先证明确实从零开始

主模型沿用 NeMo Speech 正式 v3.0.0，固定完整提交 fd6a877539710e2b98f28c43272ff81312f83417，不在训练途中追踪 main。官方离线 CTC 配置的注释表把 Large 写为 17×512、8 heads、约 120M，但 YAML 实际设为 18 层；本方案必须显式覆盖 n_layers=17。因此 “ 约 115M-class / 约 1.15 亿 ” 是规模描述，精确值须在 Day 1 实例化后用 sum(p.numel() for p in model.parameters()) 记录，不能把本文数字当作已测参数量。(固定提交、正式版本、固定配置)

使用 80-bin log-mel、25ms 窗、10ms 步长、8 倍下采样、256 subsampling channels，继承固定版完整配置的其余模型字段。att_context_size=[-1,-1]、非因果下采样及卷积意味着模型使用双向上下文；本计划验收整句离线识别。原生流式需要另一套因果前端、有限右上下文与缓存训练，不能把离线模型切块调用称为已完成实时流式。朗读语料成绩也不证明会议、医疗语音或所有口音的能力。(官方离线配置、cache-aware 路线)

从零覆盖整个推理链：声学前端的可训练层、编码器、CTC 输出层都随机初始化，不载入预训练 encoder、SSL 模型、teacher、伪标签或外部 LM。训练文本自产 tokenizer 合法，确定性信号处理和公开实现可以复用。固定版训练入口构建模型后仍会调用 maybe_init_from_pretrained_checkpoint；其检查按初始化键是否存在计数，三个键都设为 null 仍可能触发冲突。必须让 init_from_nemo_model、init_from_pretrained_model、init_from_ptl_ckpt 全部不存在，并在包装器启动时断言，不靠 “ scratch ” 目录名证明初始化。(训练入口、初始化判断)

Day 1 先建立独立源码环境。固定 README 主动测试栈包括 Python 3.13、PyTorch 2.12、CUDA 12.6/13.2；cu12 extra 固定对应 Torch，不能直接拿旧环境可导入当作本版本已验收。若现场驱动支持，候选路线是 uv sync --locked --python 3.13 --extra asr --extra cu12，随后核对 lock、导入、uv pip check、单步与两 rank DDP；

这是未来环境方案，尚未现场通过。保存源码 SHA、lock SHA256、软件版本、CUDA/cuDNN/NCCL 与 GPU 信息。若改用容器，先确认镜像实际存在，再固定 immutable digest，本文不编造 NGC 标签。(README、依赖约束)

需新增小型入口包装器，在 Trainer/模型构建前固定 pl.seed_everything(20261027, workers=True)，输出 resolved config、实际参数量、初始参数指纹和数据/tokenizer hash，保存 step 0 记录。只在 YAML 增加 seed: 不会自动完成这些动作。tiny、校准、主训练用不同目录与标签；Day 3 主模型重新随机初始化，不从已训练的 tiny 或校准权重接续。主 run 启动使用空输出目录与 resume_if_exists=false，后续只允许恢复同一 run 自产检查点，并验证架构、词表、数据与状态对应。

2. 用真实保留小时约束数据与全部评估分母

数据只采用 LibriSpeech 官方三份训练 archive，名义约 960 小时；dev-clean/dev-other 用于开发，test-clean/test-other 最后封存评价。数据为 16kHz 英语朗读、CC BY 4.0，保留许可、署名及预处理改动说明。三个训练包标称约 6.3G、23G、30G，四个 dev/test 包合计约 1.3G；这些是压缩体积，不是解压空间。优先直接读原生 FLAC，避免旧脚本批量额外转 WAV。项目暂预留 180 – 250GB 用于原包、解压、环境和有限检查点，这是待现场核对的容量预算；若再落 16-bit PCM WAV，仅 960h 音频便额外约 110.6GB。(数据发布页、官方校验和、FLAC 支持)

先校验 archive，再逐文件检查可解码、16kHz、单声道、实际时长、缺失和重复 ID/音频 hash。训练保留 0.1 – 20.0s，排除空文本或损坏条目；20 秒仅是训练吞吐策略，超长样本被排除，不能切音频后继续使用整句文本。保存每种排除原因的条数、小时与 ID。最终名称应为 “ LibriSpeech 960 训练划分的保留子集，实际 X 小时 ”，不能仍宣称全部 960h 都参与。D_clean_h 表示经检查的完整训练池，包含 train-other-500，不是只用两个 clean 分片。

数据池	未过滤参考条数	本方案用途与要求
train-clean-100	28,539	与另两份合并审计，按训练规则过滤
train-clean-360	104,014	训练；不按名称直接当成实际解码小时
train-other-500	148,688	训练；保留真实困难条件，不为好分数随意删除
dev-clean / dev-other	2,703 / 2,864	全量保留，完整 dev 用于选模
test-clean / test-other	2,620 / 2,939	全量保留，包括超过 20 秒的样本；最后各自报告

以上条数用于完整性预检，不是过滤后实测，也不是 WER 分母。LibriSpeech 原始划分说话人互斥，但额外 LM 语料的书籍去重规则不能直接推成所有声学 split 的书籍文本绝对互斥。审计 ID、音频 hash、speaker 交集，并列出可核实的 chapter/book 与规范化文本重叠；常见短语重复不自动删除，不擅改官方 dev/test。(官方数据卡、原始论文)

manifest 核心字段为 audio_filepath/duration/text；审计表另存 utterance、speaker、chapter、split、source/hash。训练、验证、测试统一小写、空白规则并保留 apostrophe，保存原文和规范化版本，执行前固定标点处理。只用保留训练文本训练 SentencePiece BPE256，corpus、tokenizer.model、vocab、manifest 全部归档 SHA256；不传入 dev/test、外部全书、SLR11 或网页。若估计数据级 CMVN，只能从 train 学习；固定的逐样本特征归一化同样在全部阶段一致。官方 tokenizer 会复用已存在的 document.txt，因此必须使用新的内容哈希目录，防止旧 corpus 混入。(tokenizer 工具、词表大小建议)

首轮单步要核对音频与文本配对、padding mask、CTC blank ID、tokenizer 往返，以及下采样后的有效帧数是否覆盖 target token 和相邻重复 token 所需的额外 blank。对随机抽取的短/中/长样本人工听读检查；异常条目

进入修复账本，不用 loss 有限替代配对正确。全量 dev/test 不设 max_duration=20，不截断。遇长句 OOM 就降 evaluation batch，必要时 batch 1；读取/推理失败仍保留失败项，不能通过删句“改善”分数。

3. 把全局 batch、学习率和恢复写成一次冻结的配方

正式起点为两卡 DDP、每卡 microbatch 64、累积 1，global batch=128。OOM 时先改为每卡 32、累积 2，仍为 global 128，再重新校准峰值显存与完整更新耗时。普通 collate 是 padding 后 stack，不是 LLM packing；每次更新的真实音频时长必须求和，不能用 128×20s 当平均值。初版不加速度扰动、不启用拼接音频或新 loader，避免同时改变时长、采样和优化口径。(有效 batch、NeMo collate)

采用 AdamW、betas=(0.9,0.98)、weight decay 1e-3、gradient clip 1.0、BF16 mixed。峰值 LR 5e-4、warmup 为计划 optimizer updates 的 3% 且上限约 5,000 步、cosine floor 5e-6 均是本项目起点，不是双 H100 上已验证的最优参数。Day 2 工程门内可锁定一次；正式主 run 不盲扫 LR。若实际计划更新数 U=110000，warmup 约 3300；若 U=60000，约 1800，不强行设 15k。先计算绝对 W=min(floor(0.03U),5000)，只设置 warmup_steps=W，不再同时开比例字段。原官方 lr=1e-3/warmup=15000/min_lr=1e-4/1000 epochs 面向 global 2K，不能照搬到本短计划，更不能把 Noam 系数当作 cosine 峰值。(官方优化配置、scheduler 实现)

下面是未来配置覆盖片段，不是独立可运行文件。须复制固定提交的完整 YAML，再覆盖这些字段；U/W 由 Day 2 真实 loader 长度、采样器补齐、累积与暴露上限计算后写成整数。计划以 50 次音频暴露为主约束，max_steps 是附加保险，不以未过滤条数近似替代实测。

```
# 待实施：先合并完整官方 YAML；这里仅列项目差异。
model:
 train_ds:
  batch_size: 64        # 每 rank；32 + accumulation=2 是退路
  min_duration: 0.1
  max_duration: 20.0
  num_workers: 8        # 按 Day 2 的 CPU/I/O 实测冻结
  pin_memory: true
 validation_ds:
  batch_size: 8         # 必须使用完整 dev，无 20s 过滤
 test_ds:
  manifest_filepath: null # 训练阶段不自动读取 test
 encoder:
  n_layers: 17
  d_model: 512
  n_heads: 8
  att_context_size: [-1, -1]
  causal_downsampling: false
  conv_context_size: null
 optim:
  name: adamw
  lr: 0.0005
  betas: [0.9, 0.98]
  weight_decay: 0.001
  sched:
   name: CosineAnnealing
   warmup_steps: W      # 待替换为 min(floor(.03*U),5000)
   warmup_ratio: null
   min_lr: 0.000005
trainer:
 devices: 2
 num_nodes: 1
 accelerator: gpu
 strategy: ddp
 precision: bf16-mixed
 accumulate_grad_batches: 1

 gradient_clip_val: 1.0
 max_steps: U           # 待换成锁定的计划 optimizer updates
```

```
  max_epochs: -1
  log_every_n_steps: 10
exp_manager:
  resume_if_exists: false
  resume_ignore_no_checkpoint: false
  resume_from_checkpoint: null
# 三个 init_from_* 键必须全部不存在；不是全设为 null。
```

正式沿用固定版 dropout 0.1 与 SpecAugment 的 2 个频率 mask、10 个时间 mask；tiny 诊断关闭增强及 dropout，不把其成绩当泛化结果。BF16 不免除检查：记录 loss、梯度、参数更新、NaN/Inf、输出长度、blank 帧率和空句率。CTC 训练初期 blank 高很常见，首几百步高 blank 本身不判永久失败；持续全空输出、loss/梯度异常或多个固定 dev 无改善才进入诊断。

未来启动接口如下，本轮不创建或执行 train_scratch_budgeted.py。该待实现包装器应调用固定官方模型/训练逻辑，并额外实现种子、初始化断言、自然音频计数、截止、全状态恢复和各 rank 一致退出。不能把本文命令说成当前仓库已有脚本。普通 Python 入口由 Lightning DDP 建两进程，避免再套两进程 torchrun 造成重复启动。示例 50 须替换成 Day 2 锁定的 cap；实际因时间截止提前停止时，不重设 cosine horizon 伪装完整收敛。

```
# 未来接口草案，当前不可直接执行。
python train_scratch_budgeted.py \
  --config-path configs --config-name fastconformer_ctc_115m_ls960 \
  --mode fresh --seed 20261027 \
  --max-natural-exposures 50 --main-deadline-utc '<T0+336h>'
# 恢复仅允许本次主 run 自产 ckpt；参数名属于待实现适配器。
```

检查点保存模型、optimizer、scheduler、precision/scaler（适用时）、global step、累计自然音频、各 rank Python/NumPy/CPU/CUDA RNG、sampler epoch/位置及配置 hash。Lightning 默认 checkpoint 保存很多训练状态，但不证明任意 worker 预取与数据游标逐位恢复；需明确能恢复到什么范围。Day 2 比较“连续 20 更新”与“10 更新→退出→新进程恢复 10 更新”，核对下一批 ID、LR、动量、loss/参数差异与暴露账本，不能只检查 load 成功。若允许重放，记录范围并计入资源；仅加载权重不是完整恢复。(checkpoint 内容及接口、固定 exp_manager)

4. 四天固定开销决定五十次暴露是否可行

T0 在未来首次获准执行时登记；日界线是其后每 24 小时，而非午夜。主训练硬截止为 T0+336h，总截止为 T0+384h。最多两卡全程占用对应 768 GPU-hours 的物理上限，主训练十二天最多 576 GPU-hours；这不是预计实际用量。CPU/下载不一定占卡，仍消耗连续墙钟。GPU 占用小时、有效训练小时、CPU/等待小时分别记账，训练失败和恢复也不能删掉。截止由统一 UTC 时钟与外部 watchdog 监督，在截止前预留完整更新和保存时间；不能只依赖可能被 min_steps/min_epochs 优先级覆盖的 Trainer max_time，也不能让挂起的 DDP 无限等待。(Trainer 时间限制)

以真实保留自然音频小时 D 定义暴露；每次采样、DDP 补齐重复、恢复重放及失败尝试处理过的音频都计入资源总账。另记“已提交到当前 checkpoint”的暴露，不能用它掩盖已烧掉的计算。tiny/校准暴露记 E_pilot，主模型记 E_main；默认 50 上限仅约束主模型，不宣称全部试验只有 50 次。验证/测试读取另列，不算训练暴露。为严格执行 E_main≤cap，预算适配器须在下一次完整累积组进入计算前，汇总两 rank 的原始 manifest 时长并检查剩余额度；不足就不接纳该组并统一保存退出，允许少于整数 epoch。不能只在 optimizer step 后才发现越界，也不能把 padding 或两个重复 logger 算两次。该适配尚未实现，必须纳入 Day 2 验收。

```
D = sum(保留训练条目的原始音频秒数) / 3600
E_main = 主 run 实际处理自然音频秒数 / (3600 × D)
E_project = E_main + E_pilot
S = 两 GPU 同一窗口实际处理的未 padding 自然音频秒数之和 / 墙钟秒数
T_main_days = D × E / (24 × S) × 1.3
```

T_total_days = T_main_days + 4

S 是双卡合计，分母是一段共同墙钟，不是两卡时间相加；包含读取、前反向、累积和同步。padding 不进入分子。若测的是稳定训练、不含定期 dev/存盘，就乘 1.3 预留 30% 工程开销；它是人为预算系数。若已用包含这些活动的端到端吞吐，则说明是否另留余量，不能不解释地重复扣 30%。校准预热约 30 – 50 更新，再用真实长短分布完成合计 200 – 500 optimizer updates，报告多个稳定窗口、低位吞吐、两卡显存、数据等待、full-dev 和保存耗时，不拿最快一批放行。

主暴露上限	假设 S（秒音频/秒墙钟，双卡）	纯训练	加 30% 的主窗口	加四天后的总时长
50	250	192h / 8.0天	约 250h / 10.4天	约 14.4天
50	300	160h / 6.7天	208h / 8.7天	约 12.7天
60	250	230h / 9.6天	约 300h / 12.5天	约 16.5天，超预算
60	300	192h / 8.0天	约 250h / 10.4天	约 14.4天

以上仅用 D=960h 作情景计算，250/300 不是已测 H100 性能。十二天主窗口需要 $S_50 \geq 960 \times 50 \times 1.3/288 \approx 216.7$，60 次则 $S_60 \geq 260$；达到边界几乎没有额外弹性。可先用约 230/280 作更保守的工程参考线，但最终以真实 D、低位稳定吞吐和剩余时钟为准。默认 50；60 只可在 Day 2 主模型启动前选定，同时冻结 LR horizon，不能 Day 12 因 WER 不够好临时加十次。

$281241/128 \times 50 \approx 109860$ 是未过滤、固定 global128 的更新数近似，60 次约 131832；过滤、sampler 补齐和累积会改变它。不能把条数、epochs、自然音频暴露与 optimizer updates 混为一谈。若两天后 S=180，剩余 288h 只能预算约 41.5 次；S=200 约 46.2 次。执行前锁定的缩量公式为 $E_cap=\min(50, H_remaining \times S_conservative/(1.3 \times D))$，H_remaining 到 Day14 截止；实际不足就报告 partial。Day 2 数据/正确性门仍未通过则先记录 preflight 失败并重拟范围，不自行顺延十六天或让未就绪主训练开跑。

预算只回答“这些暴露能否塞进时钟”，不证明 50/60 次足够获得某个 WER。主训练中保持一个种子、一条固定配方；架构、词表、数据池或优化策略变更须保留原失败 run，另列新实验及其成本。性能下降时更新预计完成量并按截止保存，不靠改变模型规模或隐瞒等待维持“完成 50 次”的说法。

5. 每天产物和最后双测试共同决定交付状态

Day 2 冻结一个 tiny 子集（32 – 64 条训练句，关闭增强）、各 dev 约 200 条的固定 dev_screen，以及完整 dev_joint。screen 按说话人、长度、子集覆盖抽样，只作健康检查；完整 dev-clean/dev-other 的总编辑错误除以总参考词数决定 checkpoint，分数相同时选更早者。每约 5 次暴露做 full-dev、每天一次 screen，可作为初始频率；实际须由 Day 2 的 dev/I/O 耗时锁定并计入 30% 余量。每约 1 – 2h 保存 last，保留完整 dev 最佳与有限里程碑，临时写完校验再发布，不能删唯一可恢复文件。(NeMo WER 口径、Experiment Manager)

日 / 连续时钟	当日输入与工作	必须保存的产物	继续、停止或调整门
Day 1 / 0 – 24h	官方源码、archive 与现场资源；建环境、校验下载、开始全量解码与 split 审计	commit/lock、环境与资源清单、校验和、数据审计进度	容量/下载阻塞记账；不以仅 100h 小跑冒充全数据就绪
Day 2 / 24 – 48h	冻结数据/tokenizer；tiny、双卡 200 – 500 更新校准、真实恢复、dev 测时	D/N/过滤表、tiny 预测、S/显存、恢复对照、唯一主配置及 U/W/cap	tiny WER≤5%、CER≤2%为诊断目标；配对、CTC、计分或恢复失败先修；未准备好则重拟范围，不顺延

日 / 连续时钟	当日输入与工作	必须保存的产物	继续、停止或调整门
Day 3 / 48 – 72h	通过全部门后，全新随机主模型启动	step0 指纹、无载权重记录、首个完整 ckpt、暴露/LR/loss 台账	非有限梯度、非法 token、长度/计数错误立即停；不从 pilot 权重继续
Day 4 / 72 – 96h	唯一主 run；第一次固定 screen、低位 S 与剩余量预测	screen 逐句预测、empty/blank、恢复文件索引	早期 blank 高结合 loss/非空输出趋势判断；吞吐下降修正预计暴露
Day 5 / 96 – 120h	按锁定里程碑执行第一轮 full-dev	两个 dev 的 S/D/I/N、早期稳定 checkpoint 基准	数据泄漏或错误配对使 run 无效；不删难句修分数
Day 6 / 120 – 144h	持续同一配方；核对梯度、音频计数和恢复日志	每日 ckpt、曲线、E_main/E_project、GPU-hours	只修基础设施/正确性缺陷并记影响，不做每日 LR 搜索
Day 7 / 144 – 168h	中期审计；比较已耗时与 Day14 可完成量	预算预测、替换/删除/插入样例、故障表	多次 dev 无改善先有时限诊断；持续故障侵占尾部窗口则提前停
Day 8 / 168 – 192h	screen 与既定 full-dev；比较早期稳定 checkpoint	全 dev 最佳指纹、相对 WER 改善、输出长度变化	单次 dev 波动不换 seed；查 loss 改善但解码不动的原因
Day 9 / 192 – 216h	样本覆盖、重复、1 – 3h 稳定吞吐与磁盘审计	自然音频总账、padding/I/O/显存、ckpt 空间清单	数据读取/磁盘风险优先处理；保留唯一可恢复状态
Day 10 / 216 – 240h	核对剩余窗口；开始汇总报告	当前 full-dev best/last、实际暴露和 partial 风险	余量不足只下调预计完成量，不隐藏失败或改变模型规模
Day 11 / 240 – 264h	固定最终解码/计分接口，错误分析只读 dev	标准化版本、greedy 配置、报告 schema	test 继续封存；已达 cap 就停止，不利用空余自动加练
Day 12 / 264 – 288h	最后阶段候选 full-dev、核对停止条件	候选及哈希、cap/deadline 状态	50 不得临时改 60；预选 60 也受同一 Day14 截止
Day 13 / 288 – 312h	估算下次保存/full-dev 耗时，准备停止与导出	终止清单、恢复检查、候选索引	不开新种子、LM、TTS；恢复不跨 Day14
Day 14 / 312 – 336h	达暴露 cap 或本日末硬停，二者先到者	last、完整资源/失败账本、最多三个 full-dev 候选	不等整数 epoch；实际 37.6 次就报告 37.6 次，不读 test 选模型
Day 15 / 336 – 360h	按预定 full-dev 规则确定唯一模型；完整双 test 最终计分	模型/tokenizer/解码哈希、两份逐句预测与计分表	失败句修读取/计分并留重跑原因；不因 WER 差调参再测
Day 16 / 360 – 384h	重新加载导出模型，用 dev 音频做单条推理 smoke、报告与公开材料审查	权重/配置清单、完整双测试、数据/时钟/暴露表、复现与局限	384h 到时交真实状态；缺测试/恢复证据即标未完成

tiny 最多约 2 – 6h 诊断，达到目标即停；它只检验实现能否学习训练句。主训练以 warmup 后第一个稳定 full-dev checkpoint 为早期参照，后续记录 relative_improvement=(WER_early − WER_now)/WER_early，并同时报两个子集与合并分数。预期后续多个固定 dev 显示可辨文字、非空率提高、相对 WER 下降；若 warmup 后连续两次 full-dev 均无改善且输出持续全空，先查 blank/token 索引、CTC 长度、音频配对与 LR，再决定提前停止。不能靠等待更多天代替诊断，也不把高 blank 帧率单独当故障。

最终模型、tokenizer、文本规则和 greedy 解码冻结后，完整原始 test-clean/test-other 各进行一次最终评价，无外部 LM、无 test 提示。每条保存原始/规范化 ref 与 hyp、S/D/I/N 和字符编辑分子分母；汇总 WER=(S+D+I)/N_words、CER、空句率、失败数、时长及长度分桶，不能平均逐句 WER。预期预测数必须

分别为 2620/2939；长句降 batch 重试也不丢弃。缺失、无法解码或推理失败的条目保留空 hyp，按完整参考计删除错误并单独报告失败；若参考与计分本身无法完成，则标 INCOMPLETE_16D，不得删句后报完整分数。任何读取/计分正确性修复导致的重跑都保留旧版本、原因与新 hash，测试好坏不能重新触发训练或挑 checkpoint。Day 16 重载 smoke 只用 dev 音频，不通过再次测试挑模型。

下面是固定版官方评价入口的未来模板，使用导出的本次自训模型；other 用另一份完整 manifest 与输出文件。先在 dev 验证接口与文本规则；test 阶段只执行冻结协议。CER 从同一批已保存预测计算，避免再次解码产生不同候选。(官方 eval 接口、BF16 推理字段)

```
# 未来评价模板；变量、完整 manifest 与 best.nemo 目前尚未生成。
python "$NEMO_ROOT/examples/asr/speech_to_text_eval.py" \
 model_path="$RUN/best.nemo" pretrained_name=null \
 dataset_manifest="$DATA/test_clean_full.jsonl" \
 output_filename="$RUN/eval/test_clean.jsonl" \
 batch_size=8 amp=true amp_dtype=bfloat16 \
 ctc_decoding.strategy=greedy_batch use_cer=false \
 text_processing.do_lowercase=true text_processing.rm_punctuation=false \
 scores_per_sample=true
```

预先设置两个计分 sentinel：参考拷贝应为 0% WER，非空参考配空预测应为 100%；它们验证计分器，不是识别模型 baseline。随机初始化模型可在固定 screen 留初始 loss/WER，WER 超过 100% 时原样报告。可选预训练 inference comparator 必须独立命名，仅作测量对照，不能把其权重、特征、转写或伪标签带入 scratch 训练，也不能拿网上分数冒充本地结果。

建议首轮项目质量目标为 完整 test-clean WER≤10%、test-other WER≤25%，同时完整报告 CER 与错误分解；这两条阈值是负责人选定的项目验收线，不是官方结果、不是 50 次暴露或十六天保证。训练集 WER、screen 最佳句、clean 单一分数或加 LM 结果不能替代它。单种子和朗读语域的局限写入报告，不把两个测试集通过扩大成普遍可用。

判定维度	最终应填写的状态	所需证据
执行	PLANNED / PREFLIGHT_PASSED / MAIN_RUNNING	方案，或数据/tiny/吞吐/恢复门真实通过，或唯一主 run 在运行
主训练	MAIN_STOPPED_FULL / MAIN_STOPPED_PARTIAL	达锁定 cap，或因截止/故障停止；列真实 E_main 与 E_project
交付	DELIVERED_16D / INCOMPLETE_16D	384h 内模型可重载、双测试与完整账本齐备，或明确列出缺项
质量	NOT_EVALUATED / TARGET_MET / TARGET_MISSED / INVALID	双测试未完、两项均达标、至少一项超标，或泄漏/初始化/计分错误使结论无效

本轮真实状态仍是 PLANNED / NOT_EVALUATED。未来最有价值的结论可以是“ 按时交付，但只完成 X 次且未达质量目标 ”，前提是保留正确分母和全部证据。提交代码、说明、配置与脱敏日志时审查公开范围；不把私有主机/IP、凭证、会话标识、个人路径、原始大音频或未经审核的权重推到公开仓库。十六天结束后，下一步是否增加训练、数据或转向流式，应由这次失败与误差证据重新立项。