用十六天验证从零 VITS 基线

状态：方案，未执行；日期：2026-10-27。 PDF 阅读版 · 推荐 ASR 主方案。TTS 是另一项独立选择：两张 H100 的同一段十六天不能同时完整提供给 ASR 和 TTS。本方案只做英语、单音色、离线合成，目标是得到可审计、能试听的基线，不承诺人声级质量。所有兼容性改动、训练与评价适配器均待实现，本轮没有安装、下载或训练。

约二十四小时单音色数据足以限定问题

选用 LJ Speech 1.1 + VITS。数据包含 13,100 段、约 24 小时、一个说话人，采样率 22,050 Hz，来源是七本非虚构书籍；官方提供原文与规范化文本，并说明原始录音经过 MP3 编码。首选锁定 VITS 官方 filelists 的 12,500 train / 100 validation / 500 test，核验 ID/音频 hash 不交叉，列出规范化文本重复，不擅改官方 split；报告 loader 过滤后的真实条数和时长。保留原采样率，审计缺失、静音与幅度；测试只说明同一个声音的保留文本表现，不声称跨书籍、未见说话人或克隆能力。按整书分组是可选后续实验，需先重建可信来源映射，不能凭编号猜测。(数据官方说明、官方训练清单、验证清单、测试清单)

VITS 所有可训练模块从随机权重开始，包括文本/后验编码器、flow、时长预测器、波形生成器和判别器，不加载预训练声码器、codec、teacher 或神经 G2P。使用固定版本的 eSpeak 规则与词典生成音素，归档前端、符号表和文本哈希；推理只输入文本。VITS 的波形生成器采用 HiFi-GAN 结构并不要求载入其权重。参数量先称数千万量级，执行时分别计数 G、D 和实际推理路径。(VITS 论文、模型实现、前端、eSpeak 机制)

先验证旧代码，再决定完整更新数

锁定官方代码 commit 和现代 H100 环境，先检查 Cython MAS、STFT、旧依赖、AMP 与双卡 DDP。官方训练器内部使用 mp.spawn，原端口 80000 无效，拟改为未占用的 29521；保留内部 spawn 时只启动一次 Python，不套 torchrun。必须新增显式 fresh/resume、max_steps、墙钟截止和完整状态保存，避免输出目录残留 G/D 导致自动续训。原检查点不足以证明精确恢复，需保存 scheduler、scaler、global step、各 rank RNG 和 sampler 状态，再做中断对照。(训练代码、依赖、检查点)

建议 每卡 batch 32、两卡 global 64，显存不足则每卡 16，重新核算预算。以 AdamW lr=2e-4, betas=(0.8,0.99)、8192-sample 片段和官方联合损失起步；FP16+scaler 先验收，敏感运算保留 FP32。官方按 epoch 衰减，batch 改变会改变同一步数的累计衰减，必须记录。一次更新包含完整 D 和 G 更新。原论文用四张 V100、每卡 64，训练 800k 步；本项目 300k 只是待校准上限，不能当作论文收敛点。(官方配置、论文训练设置)

预热 50 个完整更新，再测 200 – 500 个更新，计入数据等待、通信、验证和保存。可做步数=floor(可用训练秒数/实测秒每完整更新)。十天训练窗口做 300k 步要求平均不超过 2.88 秒；另留 20% 机动则要求不超过 2.304 秒。实测不满足就降低 step cap，预算不足不自动续期。

时间	输入与产物	进入下一阶段的门槛
Day 1 – 2	数据划分、前端、环境；32 – 64 条 tiny 过拟合；双卡校准与恢复记录	配对正确、更新有限且有效、可生成可理解的训练短句；恢复与 fresh 检查通过
Day 3 – 12	新随机主 run；固定验证文本、对齐图、音频与 G/D 全状态	预先锁定 cap/deadline；无持续崩溃、严重漏读或静音；按验证集保存最佳模型
Day 13 – 14	停止训练、冻结模型与合成参数；生成保留测试句	测试文本未用于选模，短/长句、数字和缩写均覆盖
Day 15 – 16	盲听、自动评价、失败列表、音频画廊与预算报告	交付配置、哈希、实际 steps/GPU 小时及 WAV；不足如实记未收敛

用完整读句与盲听判断基线是否成立

外部固定 ASR 可辅助报告合成语音及对应自然录音的 WER/CER、漏词、重复和失败率，只用于测量，不进入训练；它的误差不能代表音质。随机排列自然录音和模型音频，统一播放响度，让英语熟练听者评价自然度与可懂度，报告实际人数、样本量和区间。人数不足就称内部试听，不宣称可靠 MOS。建议预先固定 100 条未见测试文本，目标为 ≥90% 可理解且完整读完，静音/循环/截断合计≤5%；外部 ASR CER≤10% 仅作辅助指标，另检查爆音与漏词。这些是项目目标而非保证，未达标如实报告。(论文主观评价方法)

十六天硬上限包括下载、工程、等待和失败，最多占用 768 GPU 小时，实际占用另记；第十六天交付已有证据。若只给十天，压缩为两天准备、六天训练、两天评测，重新计算 cap，不能沿用十六天训练量。